



# GOURMET

## 사용자 평점과 리뷰 텍스트를 고려한 딥러닝 기반 맛집 추천 시스템

지도 교수 : 이청용 교수님

팀원 : 정민규, 이준규, 유종범, 김성훈, 강범준

# 목차

## 1. 연구 수행 목적

- 1.1. 연구 배경
- 1.2. 연구 정의

## 2. 연구 결과물의 개요

- 2.1. 연구 과정
  - 2.1.1. 활용 데이터
  - 2.1.2. 측면 기반 감성분석 (ABSA)
  - 2.1.3. 모델 설계
- 2.2. 모델 학습
- 2.3. 사용 평가지표
- 2.4. 실험 결과

## 3. 프로젝트 수행 추진 체계 및 일정

- 3.1. 각 조원의 조직도
- 3.2. 역할 분담
- 3.3. 주 단위의 프로젝트 수행 일정

## 4. 참고 문헌

# 1. 연구 수행 목적

## 1.1. 연구 배경

디지털 정보가 급증함에 따라, 사용자의 의사결정을 지원하는 추천 시스템이 핵심 기술로 부상하였다. 특히 외식 산업 분야에서 맛집 추천 시스템은 사용자에게 방대한 선택지 중 최적의 대안을 제시하는 중요한 도구로 역할을 수행한다. 그러나 사용되는 다수의 추천 시스템은 사용자가 부여한 단일 평점이나 '맛'과 같은 특정 속성에 과도하게 의존하는 경향이 있다. 이러한 접근법은 속성 편향 문제를 야기하며, 사용자의 다면적인 선호도를 온전히 반영하지 못하는 본질적인 한계를 노출한다. 예를 들어, 서비스 품질이나 가격 합리성을 중요시하는 사용자에게 단순히 맛 평점이 높은 식당을 추천하는 것은 사용자의 실질적 만족도를 저해하는 핵심 요인으로 작용한다. 따라서, 리뷰 텍스트에 잠재된 풍부한 정성적 정보를 정량적으로 분석하고 이를 추천 모델에 통합하여, 보다 정교하고 개인화된 추천을 제공하는 모델의 필요성이 대두되고 있다.

## 1.2. 연구 정의

기존 추천 시스템은 '맛'이나 '음식 종류'와 같은 특정 속성에만 의존하여 서비스, 분위기 등 사용자의 다양한 선호 기준을 반영하지 못하는 '속성 편향' 문제를 내재하고 있다. 본 연구는 사용자 리뷰 텍스트에서 추출한 다각적인 속성별 감성 정보와 사용자 평점을 통합적으로 고려하여 개인의 복합적인 선호를 만족시키는 딥러닝 기반 맛집 추천 시스템을 개발하고 그 성능을 검증한다. 이를 달성하기 위한 구체적인 연구 과정은 다음과 같이 정의된다.

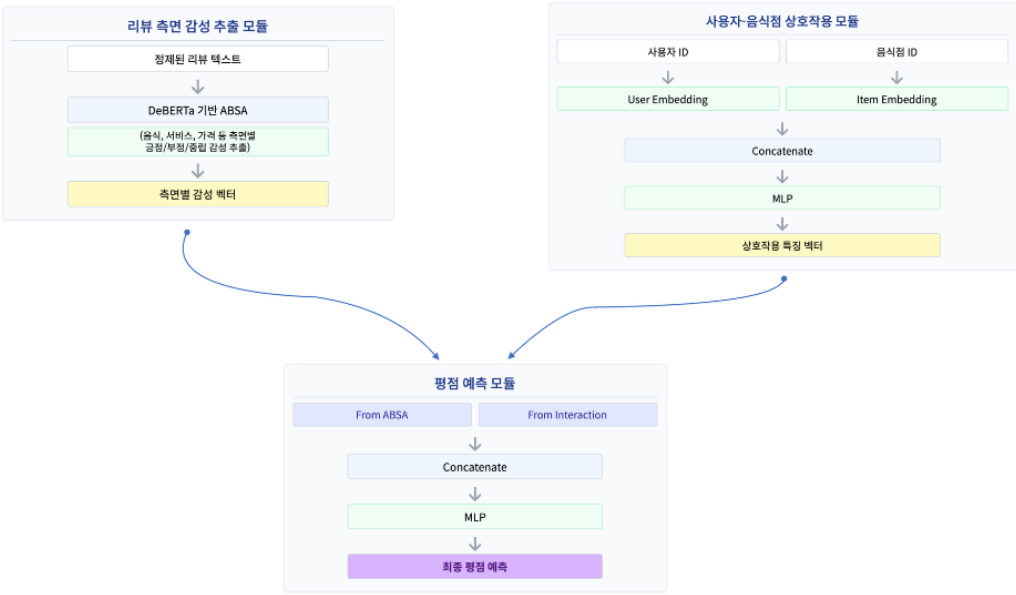


첫째, 다각적 속성 기반 감성 분석(Asspect-Based Sentiment Analysis, ABSA)을 수행한다. 최신 자연어 이해 모델인 DeBERTa를 활용하여, 리뷰 텍스트로부터 사전에 정의된 5개의 핵심 속성(음식, 서비스, 분위기, 가격, 위치)에 대한 긍정(Positive), 부정(Negative), 중립(Neutral)의 감성 점수를 정밀하게 추출하고, 이를 15차원의 감성 벡터(Sentiment Vector)로 정량화한다.

둘째, 감성 정보 융합 딥러닝 모델을 설계한다. AAT-Rec 프레임워크를 기반으로, 전통적인 사용자-아이템 상호작용을 학습하는 모듈과 리뷰에서 추출된 감성 벡터를 학습하는 모듈을 병렬적으로 구성하고, 이 두 정보를 결합하여 최종 평점을 예측하는 통합 딥러닝 아키텍처를 구현한다.

셋째, 모델의 성능을 종합적으로 평가한다. 구축된 모델의 예측 정확도를 RMSE, MAE 등 정량적 지표를 통해 측정하고, 여러 베이스라인 모델과의 비교 실험을 통해 제안 모델의 우수성과 감성 정보 활용의 유효성을 확인한다.

## 2. 연구 결과물의 개요

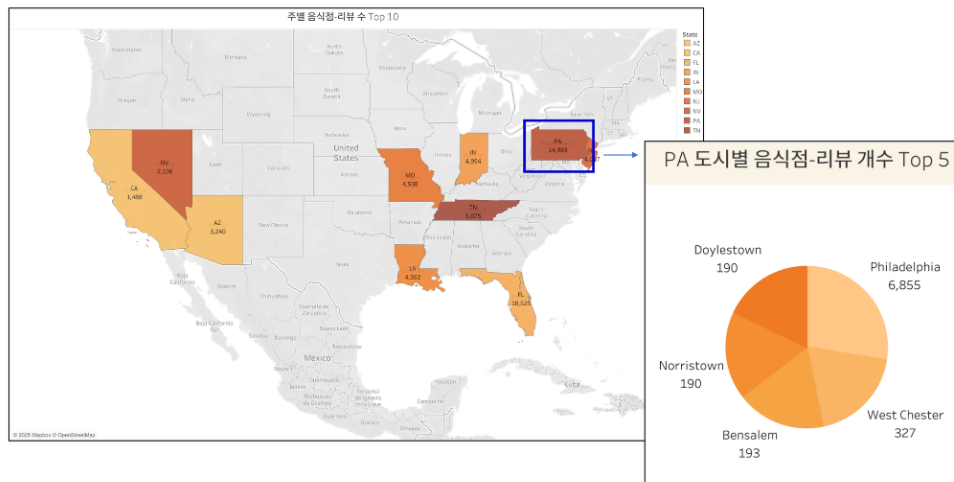


## 2.1. 연구 과정

### 2.1.1. 활용 데이터

본 연구는 대규모 리뷰 데이터를 포함하고 있는 공개 데이터셋인 Yelp Open Dataset을 활용하였다. 모델 학습의 효율성과 분석의 적합성을 확보하기 위해 다음과 같은 전처리 과정을 수행하였다.

먼저, 전체 데이터셋에서 review.json, user.json, business.json 파일을 주요 분석 소스로 선정하였다. 이후 Yelp 공식 블로그를 참조해 business.json의 카테고리를 기준으로 '음식(Food)' 및 '레스토랑(Restaurant)' 관련 업종만을 필터링하였다. 또한, 분석의 지역적 일관성을 위해 미국 내에서 리뷰 수가 가장 많은 도시 중 하나인 필라델피아(PA) 지역의 데이터로 범위를 한정하였다.



다음으로, 데이터의 신뢰도를 높이기 위해 사용자 및 리뷰 데이터를 정제하였다. 리뷰의 양과 질을 고려하여, 해당 지역 음식점에 대해 **최소 5개 이상의 리뷰**를 작성한 활성 사용자의 데이터만을 분석 대상으로 삼았다. 이는 소수의 리뷰만을 작성한 사용자에 의한 편향을 줄이고, 학습 데이터의 대표성을 확보하고자 하였다. 추가적으로 추천의 다양성을 높이기 위해, 리뷰를 남긴 **고유한 식당의 수가 5개 미만**인 사용자의 리뷰를 제거하였다. 마지막으로 모델링과 직접적인 관련성이 낮거나 중복 가능성이 있는 불필요한 컬럼(가입일, 친구 관계 등)은 분석에서 제외하여 데이터셋을 경량화하였다.

리뷰 텍스트의 경우, 자연어 처리 모델인 DeBERTa의 입력 요구사항을 고려하여 정제를 진행하였다. 과도한 전처리가 문맥적 의미를 손상시킬 수 있다는 점을 감안하여 원문의 특성을 최대한 보존하는 방향으로 진행하였다(Alzahrani et al., 2021). DeBERTa 모델의 최대 입력 토큰(512)을 초과하는 리뷰의 비율은 1.58% 정도로 나타났다. 이에, 해당 리뷰들은 모델의 입력 길이에 맞춰 후반부를 절단하여 처리하였다.

최종적으로, 상기의 전처리 과정을 거친 각 데이터를 고유 ID(user\_id, business\_id)를 기준으로 병합하여 단일 분석 데이터셋을 구축하였다. 이를 통해 **총 447,796개의 리뷰 데이터**를 확보하였다.

### 2.1.2. 측면 기반 감성 분석 (ABSA)

리뷰 텍스트에 내재된 다각적인 평가를 추출하기 위해, 본 연구에서는 **측면 기반 감성 분석**(Aspect-Based Sentiment Analysis, ABSA) 기법을 도입하였다. ABSA는 리뷰 전체의 긍정/부정을 판단하는 것을 넘어, “음식은 훌륭했지만 서비스는 실망스러웠다”와 같이 하나의 리뷰 안에 공존하는 여러 속성(Asspect)에 대한 개별적인 감성을 식별하는 고도화된 분석 기법이다. 본 연구에서는 선행 연구들을 참조하여 레스토랑 평가의 핵심 속성으로 **음식(Food)**, **서비스(Service)**, **가격(Price)**, **분위기(Ambience)**, **위치(Location)**의 5가지를 정의하였다.

감성 추출을 위해, 최신 자연어 이해 모델 중 하나인 **DeBERTa**(Decoding-enhanced BERT with disentangled attention)를 활용하였다. DeBERTa는 단어의 내용과 위치 정보를 분리하여 처리하는 어텐션 메커니즘을 통해 문맥을 효과적으로 이해하며, 특히 특정 속성과 관련된 감성 표현을 연결하는 작업에서 높은 성능을 보인다. 각 리뷰 텍스트에 대해, 5개의 속성별로 긍정, 부정, 중립의 감성 확률 점수를 산출하여, 이를 15차원(5개 측면 × 3개 감성)의 감성 벡터(Sentiment Vector)로 정량화하였다. 이 벡터는 각 리뷰가 담고 있는 다차원적 평가 정보를 압축적으로 표현하며, 후속 딥러닝 모델의 핵심 입력 특성으로 사용된다.

### 2.1.3. 모델 설계

본 연구에서 제안하는 추천 모델, **AS-Rec** (Aspect-based Sentiment Recommender)는 선행 연구 **AAT-Rec 프레임워크(우수현 외, 2025)**에 기반하여 설계되었다. 이 모델은 사용자-아이템 상호작용 정보와 리뷰의 감성 정보를 효과적으로 융합하는 것을 목표로 하며, 크게 세 가지 모듈로 구성된다.

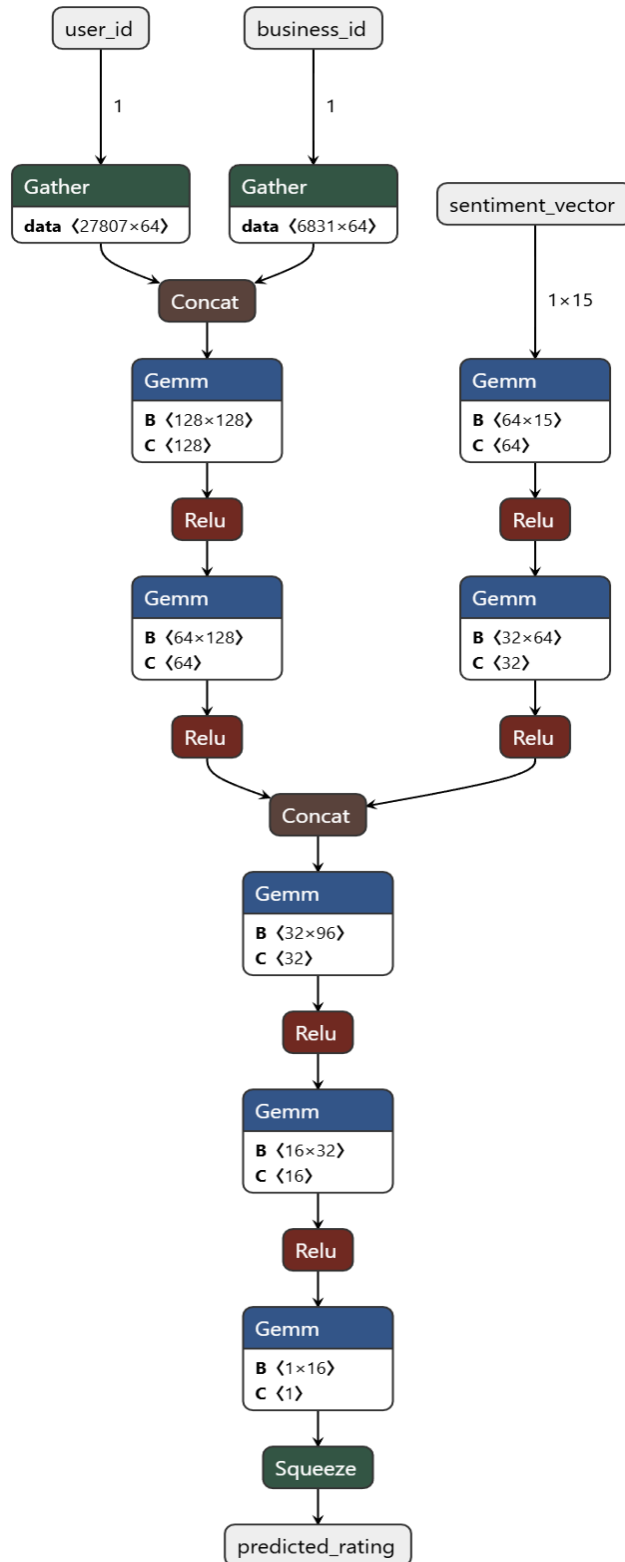
**리뷰 측면 감성 모듈** : 이 모듈은 ABSA를 통해 추출된 **15차원의 감성 벡터**를 입력으로 받는다. 감성 벡터는 `aspect_mlp_dims`로 정의된 은닉층을 갖는 별도의 MLP를 통과하며, 여러 측면 간의 관계 및 감성 패턴이 평점에 미치는 영향을 학습한다.

**사용자-아이템 상호작용 모듈** : 이 모듈은 전통적인 협업 필터링의 아이디어를 계승한다. 사용자 ID와 아이템(음식점) ID는 각각 고유한 임베딩 층(Embedding Layer)을 통해 `embedding_dim` 차원의 잠재 벡터(Latent Vector)로 변환된다. 두 잠재 벡터는 결합되어 `user_biz_mlp_dims`에 정의된 은닉층 구조를 갖는 다층 퍼셉트론(MLP)에 입력된다. 이를 통해 **사용자와 아이템 간의 복잡하고 비선형적인 상호작용 패턴을 학습**한다.

**평점 예측 모듈** : 상기 두 모듈에서 출력된 특징 벡터는 다시 결합되어 최종 예측을 위한 MLP에 입력된다. 이 MLP는 `final_mlp_dims` 구조를 가지며, 최종적으로 **사용자가 아이템에 부여할 것으로 예상되는 평점 값을 예측**한다.

## 2.2. 모델 학습

학습 과정을 시각화하면 다음과 같다.



본 연구의 실험은 Python 언어와 PyTorch 딥러닝 프레임워크를 기반으로 수행되었다. 하드웨어 환경은 GPU(NVIDIA GeForce RTX 3070)를 활용하여 모델 학습 및 평가의 효율성을 높였다. 모델 학습 과정에서는 손실 함수로 평균 제곱 오차(MSELoss)를 사용하였으며, 최적화 함수는 Adam, 활성화 함수는 ReLU를 채택하였다. 학습 데이터는 (사용자, 아이템, 감성 벡터, 실제 평점)로 구성되며, 모델은 예측 평점과 실제 평점 간의 오차를 최소화하는 방향으로 파라미터를 업데이트한다. 과적합을 방지하고 일반화 성능을 높이기 위해, 손실이 일정 기간(patience=10) 동안 개선되지 않으면 학습을 조기 종료(Early Stopping)하는 장치를 마련하였다.

전처리된 447,796개의 데이터는 학습(Training), 검증(Validation), 테스트(Test) 데이터셋으로 각각 70:10:20의 비율로 분할되었다. 모델의 하이퍼파라미터는 랜덤 탐색(Random Search)과 같은 기법을 통해 최적화되었으며, 최종적으로 채택된 주요 파라미터는 다음과 같다.

파라미터명	값	설명
embedding_dim	64	사용자 및 아이템 ID를 표현하는 잠재 벡터의 차원 수
learning_rate	0.001	모델 학습 시 가중치를 업데이트하는 학습률
batch_size	128	한 번의 학습 단계에서 사용하는 데이터 샘플의 수
user_biz_mlp_dims	[128, 64]	사용자-아이템 상호작용을 학습하는 MLP의 은닉층 차원
aspect_mlp_dims	[64, 32]	리뷰의 측면별 감성 정보를 학습하는 MLP의 은닉층 차원
final_mlp_dims	[32, 16]	최종 평점 예측을 위해 결합된 특징을 학습하는 MLP의 은닉층 차원

### 2.3. 사용 평가지표

제안된 모델의 예측 성능을 정량적으로 평가하기 위해 네 가지 주요 지표를 사용하였다. 평균 제곱 오차(Mean Squared Error, MSE)는 예측값과 실제값의 차이를 제곱하여 평균을 낸 값으로, 큰 오차에 더 큰 가중치를 부여하는 특징이 있다. 평균 절대 오차(Mean Absolute Error, MAE)는 예측값과 실제값 간의 절대적인 차이의 평균으로, 오차의 크기를 직관적으로 나타낸다. 평균 제곱근 오차(Root Mean Square Error, RMSE)는 오차를 제곱하여 평균을 낸 후 제곱근을 취한 값으로, 큰 오차에 더 큰 패널티를 부여하는 특징이 있다. 마지막으로, 평균 절대 백분율 오차(Mean Absolute Percentage Error, MAPE)는 실제값 대비 오차의 상대적인 크기를 백분율로 표현하여 직관적인 해석을 돕는다. 이 지표들은 **모두 값이 낮을수록 모델의 예측 정확도가 높음을 의미한다.**


### 2.4. 실험 결과

최종 모델의 성능 평가 결과, MSE 0.4697, RMSE 0.6854, MAE 0.5390, MAPE 18.79% 라는 우수한 예측 정확도를 달성하였다. 이는 모델이 사용자의 실제 평점을 평균적으로 약 0.54 점의 오차 내에서 예측함을 의미하며, 5점 척도 시스템에서 매우 신뢰도 높은 수준의 성능이라 할 수 있다.



Model	MSE	RMSE	MAE	MAPE
UBCF	1.2407	1.1139	0.8655	35.25%
IBCF	1.3896	1.1788	0.8947	36.40%
SVD	1.0684	1.0336	0.8039	32.46%
NeuMF	1.1629	1.0784	0.8518	34.09%
AFRAM	0.7952	0.8917	0.6711	25.72%
UCAM	0.5937	0.7705	0.5962	21.58%
<b>AS-Rec</b>	<b>0.4697</b>	<b>0.6854</b>	<b>0.5390</b>	<b>18.79%</b>

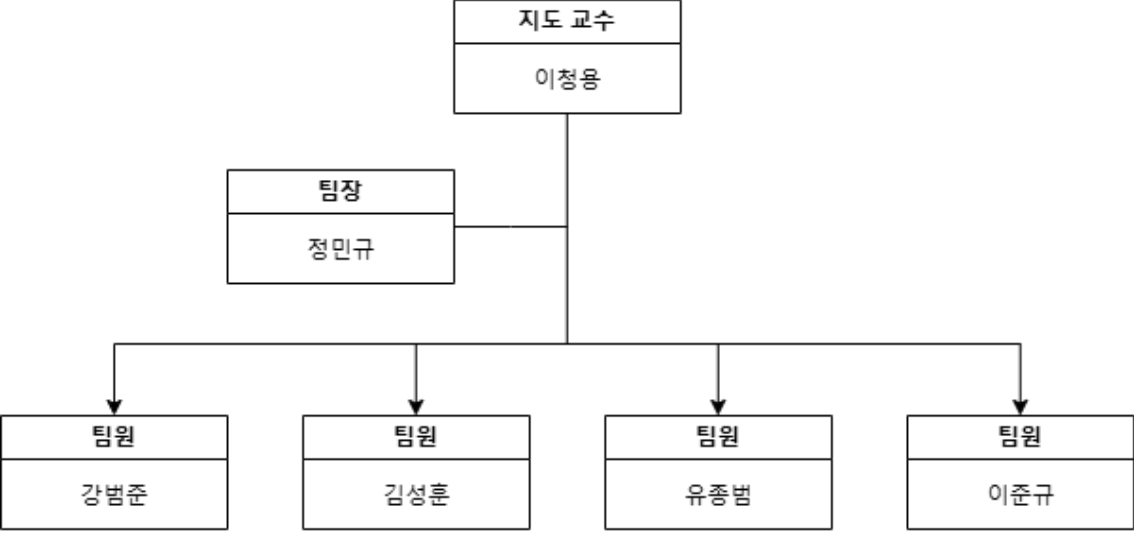
또한, 제안 모델(AS-Rec)의 성능을 검증하기 위해 SVD, NeuMF, UCAM 등 여러 베이스라인 모델과 비교 실험을 진행하였다. 그 결과, AS-Rec 모델은 모든 평가지표에서 다른 모델들을 능가하는 성능을 보였다. 특히, 사용자-아이템 상호작용 정보만을 사용하는 NeuMF 모델이나, 리뷰 텍스트의 감성을 단일 점수로만 활용하는 모델들과의 성능 격차는 리뷰 텍스트 내의 '다각적인 측면별 감성'을 정교하게 모델링하는 것이 추천 성능 향상에 결정적인 역할을 함을 보여준다.



이러한 결과는 본 연구의 핵심, 즉 리뷰 텍스트에 담긴 다면적 감성 정보를 딥러닝 모델에 효과적으로 통합함으로써 추천의 개인화 수준과 정확도를 높일 수 있다는 사실을 확인한다. 모델은 단순히 사용자의 과거 평점 패턴만을 학습하는 수준을 넘어, 사용자가 각 속성에 대해 어떻게 느끼고 있는지를 학습함으로써 보다 깊이 있는 이해를 바탕으로 추천을 생성하게 되는 것이다.

### 3. 프로젝트 수행 추진 체계 및 일정

#### 3.1. 각 조원의 조직도



#### 3.2. 역할 분담

이름	역할
정민규	시각화 (Visualization)
유종범	모델링 (Modeling)
이준규	모델링 (Modeling)
강범준	발표, 포스터, 문서 정리 (Presentation & Docs)
김성훈	발표, 포스터, 문서 정리 (Presentation & Docs)

### 3.3. 주 단위의 프로젝트 수행 일정

주차	활동 내용
2주차	팀 결성, 주제 아이디어 논의, 지도교수 면담 진행
3주차	문제 정의 및 데이터 수집 전략 수립, 추천 모델 후보 선정
4주차	제안서 작성, 감성 분석 모델(deBERTa) 논의, 추천 전략 구체화
5주차	ABSA 모델 탐색, Yelp 리뷰 전처리 기획, 데이터 공유 체계 이관
6주차	추천 시스템 및 감성 분석 논문 스터디, ABSA 설계 논의
7주차	ABSA 시범 실험, 감성 점수 기반 추천 설계, 사용자 편향 분석
8주차	역할 분담 체계 수립, 감성 점수 보정 로직 구성, 전시 포스터 구성 논의
9주차	하이브리드 추천 모델 정리, 시각화 구성, RMSE 성능 실험
10주차	이중 추천 구조 단순화, 감성 기반 추천 로직 확립, 전시 자료 구성 시작
11주차	15차원 감성 벡터 출력, 책자 제작 및 전시 심사 준비
12주차	하이브리드 추천 시스템 구현, 모델 성능 측정(RMSE/MAE 등), 전시회용 패널 최종 제출
13주차	전시회 발표 준비 및 리허설, 발표자료/시연자료 최종 구성, 역할 분담 및 질의 응답 시나리오 정리
14주차	최종 보고서 작성, Github 저장소 정리
15주차	최종 결과물 제출

## 4. 참고 문헌

### [국내 문헌]

이청용, 최사박, 신병규, 김재경. 「온라인 호텔 리뷰와 평점 불일치 문제 해결을 위한 딥러닝 기반 개인화 추천 서비스 연구」. 2021.

우수현, 박선우, 김려, 이흠철, 이청용, 김재경. 「고객의 속성별 중요도를 반영한 속성 기반 감성 분석(ABSA)을 이용한 레스토랑 추천 시스템」. 2025.

이승우, 강경모, 이병현, 이청용, 김재경. 「사용자의 정성적 선호도와 정량적 선호도를 고려하는 추천 시스템 성능 향상에 관한 연구」. 2022.

양시건, 이청용, 장동수, 김재경. 「속성 기반 감성분석을 활용한 개인화 레스토랑 추천시스템에 관한 연구」. 2023.

### [국외 문헌]

Kim, Jae-kyeong, Ilyoung Choi, Qinglong Li. "Customer Satisfaction of Recommender System: Examining Accuracy and Diversity in Several Types of Recommendation Approaches.". Sustainability. 2021.

He, Pengcheng, Liu, Xiaodong, Gao, Jianfeng, Chen, Weizhu. "DeBERTa: Decoding-enhanced BERT with Disentangled Attention". 2021.

Alzahrani, E., Jololian, L., "How Different Text-preprocessing Techniques Using the BERT Model Affect the Gender Profiling of Authors" (CMLA), 2021.

### [기타 자료]

<https://docs.developer.yelp.com/docs/resources-categories>

<https://www.localvisibilitysystem.com/docs/yelp-business-categories-list.pdf>